

GOAI 赛道三

虚拟细胞赛题解读

基于酵母扰动蛋白质组数据的条件响应预测

周梓卓 | 西湖大学博士生 Guomics

报告摘要 本赛题要求模型根据酵母菌株、化合物及实验条件，预测对应样本的高维蛋白质组响应。赛题的核心并不是在已知组合上做插值，而是检验模型能否将训练数据中学到的生物规律迁移到新化合物、新菌株以及二者同时未知的场景。本文围绕任务定义、数据处理、验证设计、提交尺度、基线结果和可进一步探索的建模方向，对赛题作一份完整说明。

1. 赛题背景与科学问题

虚拟细胞模型希望在计算机中近似细胞对外界扰动的响应。与图像或文本任务不同，这里的输出不是一个类别，而是一组具有明确生物意义的分子读数。本赛题以酿酒酵母为对象，使用质谱蛋白质组数据描述不同遗传背景、化合物处理和培养条件下的细胞状态。

从应用角度看，这类模型可以帮助研究者在开展实验前筛选更有价值的菌株－化合物组合，缩小需要实际测量的范围。从方法角度看，任务同时包含高维输出、缺失观测、批次差异和实体级零样本泛化，是一个比常规随机切分更接近真实科研使用场景的问题。

2. 任务定义与数据组成

每个样本由菌株、化合物、培养基、温度、处理时间以及测量上下文共同描述。模型的目标是输出该样本对应的完整蛋白质组强度向量。可以把任务简化写成：

菌株 + 化合物 + 实验条件 → 5,243 维蛋白质组响应

数据文件	样本数	主要内容	开放情况
训练及验证元数据	8,958	15 个条件与测量字段	开放
训练及验证蛋白质组	8,958	5,243 个蛋白的 raw intensity	开放
测试元数据	4,454	15 个条件与测量字段	开放
测试蛋白质组真值	4,454	评测参考	仅供参考

元数据中的字段可以分成两类。菌株、化合物、培养基、温度和处理时间描述模型真正需要学习的生物条件；数据来源、仪器和实验板等字段描述测量过程。后者能够解释一部分系统差异，但不能直接等同于生物机制。建模时需要把生物信号与观测过程分开处理。

3. 数据预处理与缺失值规则

蛋白质组中的 NA 主要来自检测限、肽段覆盖和实验条件差异。NA 不是数值 0，也不应在读入数据后统一填成 0。一个稳妥的处理流程如下。

- **样本对齐：**以 sample_ID 为唯一键对齐元数据和蛋白矩阵，不能依赖两张表当前的行顺序。
- **蛋白过滤：**仅使用训练行计算缺失率，删除在 80% 及以上训练样本中缺失的蛋白。
- **缺失掩码：**其余蛋白保留观测 mask，训练损失和验证指标只在真值存在的位置计算。
- **尺度转换：**对非缺失的 raw intensity 做 log2；模型内部如需标准化，均值和标准差也只能从训练集估计。

按当前冻结划分，split_final=train 共 5,920 个样本。以这些样本计算缺失率后，5,243 个蛋白中保留 4,232 个，删除 1,011 个。这个保留列表必须由训练数据产生，不能借用验证集或测试集真值。

3.1 输出尺度

参赛者提交 log2 intensity。主办方评测统一在 log2 尺度上比较。z-score 等标准化只适合模型内部训练，不能直接作为 prediction.csv 提交；如果模型在标准化空间训练，输出前必须还原到 log2 的生物尺度。

提交尺度	是否允许	评测端处理
raw intensity	不允许	需自行转换到 log2 后提交
log2 intensity	允许	直接进入统一评测尺度
z-score / 标准化空间	不允许	无法与其他模型在统一生物尺度上比较

4. 泛化场景与验证设计

如果只做随机划分，同一个菌株、同一种化合物甚至相似测量上下文可能同时出现在训练集和验证集。模型即使主要依赖类别均值，也可能得到看起来不错的结果。为检验真正的实体级泛化，当前验证集按“菌株是否见过”和“化合物是否见过”进行拆分。

验证场景	菌株	化合物	样本数	主要问题
val_chem_only	已见	未见	1,065	能否泛化到新化合物
val_strain_only	未见	已见	1,547	能否泛化到新菌株
val_both	未见	未见	269	能否完成双重零样本预测
val_time	按时间划分	按既定条件	157	能否在已观测时间点之间插值

三类实体划分分别对应三种不同能力：新化合物检验结构信息能否迁移，新菌株检验遗传背景表征能否迁移，双重未知则要求模型同时处理两个未见实体。**内部研究结果也需要分别报告这三类场景，不能只给出一个由样本量较大的简单场景主导的总分。**

4.1 评测逻辑

测试集蛋白质组真值随赛题数据一并发放，其成绩供参赛者自行参考。评测端在统一的 $\log_2$ 尺度上比较预测与真值。指标只在测试真值非缺失、且属于训练集保留蛋白列表的位置计算。这保证了不同提交在相同尺度和相同观测位置上比较。

评价高维蛋白质组预测时，不能只依赖样本 profile 相关性。不同蛋白天然存在很大的丰度差异，只输出每个蛋白的训练均值，也可能得到较高的全谱相关。**更有解释力的结果应同时观察绝对误差、逐蛋白表现、去除实验上下文后的残差表现，以及新化合物、新菌株和双重未知场景中的稳定性。**当前尚未公开统一评分脚本，最终指标组合以正式比赛规则为准。

4.2 数据使用约束与最终评测

训练仅可使用 train 划分的蛋白质组标签；验证集与测试集不得参与训练，也不得用于估计任何统计量（含保留蛋白列表与归一化参数）。验证集用于模型选择，测试集成绩供自行参考。外部公开资源可用于特征构建，须披露来源。

组委会另备一组独立内部评测集用于最终评审，不随赛题发放。晋级队伍须通过代码复现核验。

5. 基线模型

基线的作用不是给出一个很强的最终模型，而是**验证数据结构、缺失规则、尺度和划分是否正确**。本赛题至少应比较以下两类基线。

- **蛋白均值基线**：对每个保留蛋白计算训练集非缺失 $\log_2$ 均值，并对所有样本输出同一向量。
- **Control 基线**：对每个处理样本查找同一数据来源、仪器、实验板、菌株、培养基、温度和处理时间下的 Water/DMSO 对照，并以这些 matched control 的 $\log_2$ 蛋白质组均值作为预测。

5.1 最小可复现示例

下面的代码概括了逐蛋白均值基线的核心过程。实际运行时还需要检查 sample_ID、蛋白列顺序和输出文件格式。

```
train = metadata['split_final'].eq('train')
missing_rate = proteome.loc[train].isna().mean(axis=0)
keep = missing_rate < 0.80
y_log2 = np.log2(proteome.loc[:, keep])
protein_mean = y_log2.loc[train].mean(axis=0)
prediction = np.tile(protein_mean.values, (len(test_metadata), 1))
```

这一路径不读取测试蛋白质组真值，也不需要任何外部实体特征，因此适合用来完成第一次端到端提交。

5.2 当前数据上的诊断结果

下表使用冻结验证划分、训练集缺失过滤和 log2 mask-aware 指标得到。结果用于说明基线强弱和验证逻辑，不是正式榜单成绩。

场景	基线	样本数	log2 RMSE	Global R ²	蛋白 R ² 中位数
双重未知	蛋白均值	266	0.994	0.871	-0.064
双重未知	Matched control	266	0.382	0.980	0.809
新化合物	蛋白均值	1,015	1.004	0.868	-0.038
新化合物	Matched control	1,015	0.379	0.980	0.836
新菌株	蛋白均值	1,293	0.875	0.897	-0.036
新菌株	Matched control	1,293	0.399	0.978	0.726
时间验证	蛋白均值	128	0.869	0.900	-0.009
时间验证	Matched control	128	0.426	0.975	0.719

两种基线在能够找到 exact matched control 的同一批验证样本上比较。Control 按主办方的 Water/DMSO 映射匹配，并只在处理真值与 control 均非缺失的位置计算指标。蛋白均值的 Global R² 较高，但逐蛋白 R² 中位数仍为负；matched control 明显更强，说明同条件对照已经解释了大量实验背景和基础生物状态。后续模型需要证明自己能够在此基础上继续预测化合物特异的响应。

6. prediction.csv 的组织方式

提交文件第一列应为 sample_ID，并与测试元数据一一对应；其余列为固定顺序的蛋白预测。蛋白列必须与主办方最终确认的 feature contract 完全一致。提交值需要全部为有限数值。提交尺度固定为 log2，无需另行声明。

检查项	要求
样本数	4,454 行，与测试元数据一致
sample_ID	完整、唯一、顺序可校验
蛋白列	名称、数量和顺序与 feature contract 一致
预测尺度	log2（固定尺度，无需声明）
数值合法性	无 NA、无 inf
信息边界	生成预测的流程不得读取测试蛋白质组真值

7. 进阶建模方向

one-hot 编码只能记住训练中出现过的菌株和化合物。面对新实体时，它们都只是同一个“未知类别”，模型无法利用两个新菌株在序列上是否接近、两个新化合物在结构上是否相似。因此，真正面向零样本泛化的模型需要引入实体本身的可迁移表征（特征工程）。

7.1 菌株表征

比赛文件不会直接发布菌株或者化合物的 embedding 信息。参赛者可以自行查找公开基因组资源，建立“比赛菌株名称—genome 文件—版本—来源”的映射表。Peter 等人在 2018 年发表的 1,011 株酿酒酵母群体基因组资源可以作为重要参考。DHY210 用酿酒酵母标准菌株 S288C 作为公开、可说明的实用代理，但应明确这是一项建模假设，而不是认为两者完全等价。

在得到基因组后，可以从简单的 k-mer、变异位点或基因存在/缺失特征开始，再尝试蛋白序列聚合或 genome language model embedding。关键是保留版本和来源，保证外部特征能够复现。

7.2 化合物表征

比赛只提供化合物名称。参赛者可以自行完成名称标准化和 SMILES 匹配，再使用 Morgan fingerprint、分子图神经网络或预训练分子表示。这个环节最容易出现的问题不是模型结构，而是名称、盐型、立体异构体和数据库条目的错误对应。因此，原始名称、数据库 CID、SMILES、来源和人工复核记录都应保留下来。

7.3 联合模型的一种思路

一种自然的架构是分别编码菌株、化合物、培养条件，再通过交互模块形成生物状态表示。仪器、实验板和数据来源不直接混入实体表征，而是进入单独的 observation calibration 分支。输出端可以先预测跨化合物共享的应激反应，再预测由 chemical/genome embedding 驱动的实体特异残差，最后建模菌株与化合物之间的交互。

模型越复杂，验证越要严格。除了分别报告三类实体划分，还应与蛋白均值、control 等基线比较；同时将 chemical 或 genome embedding 整体打乱或置零，观察性能是否明显下降。如果真实 embedding 与 shuffle embedding 表现接近，就不能据此宣称模型有效利用了 embedding 信息做外推。同时，针对所预测的 protein，也可以引入一些先验信息，以期提高模型的能力

8. 总结

这道赛题表面上是一个 5,243 维回归问题，实质上考察的是模型能否从有限的酵母扰动数据中分离生物信号与测量差异，并将规律迁移到未见实体。做好这道题首先依赖清楚的数据结构：sample_ID 对齐、训练集缺失过滤、mask-aware 训练、统一 log2 评测和实体级验证。在此基础上，均值与上下文基线给出了可信的起点；genome 和 SMILES 表征则为真正的零样本泛化提供了进一步空间。

参考资料

《GOAI 赛道三参赛手册》及 WAYB/WAYC 比赛数据文件。

Peter et al. (2018), [Genome evolution across 1,011 *Saccharomyces cerevisiae* isolates](#), Nature 556:339–344.

S288C 参考基因组: [Saccharomyces Genome Database](#)